

# FORENSIC DOC ANALYZER v1.0.0

## GUIDE TECHNIQUE & MANUEL DE L'UTILISATEUR

**Auteur & Signature :** Dam-FOR3K (avec l'aide de l'IA Antigravity) • Version 1.0.0

**Plateforme :** Solution 100% Locale, Autonome et Air-Gapped (Sans Internet)

■ **OBJET DU MANUEL TECHNIQUE :** Ce document constitue le guide technique pour l'utilisation de **Forensic Doc Analyzer v1.0.0**. Il détaille pour chaque format de fichier (PDF, DOCX, XLSX, EML, MSG, OLE) les moteurs d'inspection utilisés, la signification des anomalies détectées et la traçabilité des preuves (Source Location).

## 1. Philosophie & Système de Cotation du Risque

L'application attribue à chaque document analysé un **Indice de Suspicion / Risque Forensique** gradué de **0 à 100**.

| Intervalle   | Niveau de Risque | Signification & Actions Recommandées                                                                                                                              |
|--------------|------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 0 — 24 pts   | FAIBLE / NORMAL  | Document standard ne présentant aucune anomalie critique. Structure saine.                                                                                        |
| 25 — 59 pts  | MODÉRÉ           | Présence d'éléments atypiques (ex: RSID orphelin, caviardage visuel, macro non obfusquée). Nécessite une revue de la chaîne de production.                        |
| 60 — 100 pts | CRITIQUE         | Alertes majeures (Payload OLE exécutable, exploit Follina/CVE, modèle distant UNC, timestomping sous-seconde). Risque d'attaque ou de falsification malveillante. |

**Mise en garde sur le Plafonnement par Catégorie (CATEGORY\_MAX\_CAPS) :** Afin d'éviter la saturation du score (100/100) sur des documents légitimes comportant de multiples répétitions mineures, l'outil applique un plafond maximum de points attribuables par catégorie (ex: RSID Orphelin plafonné à 20 pts max, Auteur Tiers à 10 pts max).

## 2. Moteurs d'Analyse & Interprétation par Format

### 2.1. Documents Microsoft Word (.docx, .docm, .doc)

#### A. Métadonnées Auteur vs Modificateur :

- *dc:creator* (Créateur d'origine) vs *cp:lastModifiedBy* (Dernier modificateur).
- **Interprétation :** Une différence entre le créateur et le dernier modificateur est fréquente en entreprise. En revanche, si le créateur est anonyme ou généré par un outil automatisé (ex: 'User', 'Admin'), cela constitue un indice d'anonymisation.
- ■ **Source de la preuve :** docProps/core.xml -> <dc:creator> & <cp:lastModifiedBy>

#### B. Cartographie des Sessions d'Édition RSID (Revision Save IDs) :

- **Qu'est-ce qu'un RSID ?** Un RSID est un identifiant hexadécimal à 8 caractères généré par Word lors de chaque sauvegarde.

- **RSID Orphelin (non déclaré)** : Présence d'un RSID dans le texte (word/document.xml) qui n'est **PAS** répertorié dans le registre officiel word/settings.xml.
- **Interprétation forensique** : C'est la preuve irréfutable que ce passage a été **copié-collé depuis un document Word externe** ou injecté par un script tiers.
- ■ **Source de la preuve** : word/document.xml -> Attribut w:rsidR (absent de word/settings.xml)

#### C. Timestamps ZIP Uniformes Récents (Word 2021/365 en 2026) :

- **Interprétation** : Dans la norme historique OOXML, les XML internes sont figés à l'époque ZIP MS-DOS (1980-01-01). Cependant, lors d'un '*Enregistrer sous...*' dans Word 2021/365 sur Windows 11, Word applique la date courante de la sauvegarde à tous les fichiers XML. **Si tous les XML portent la même date récente uniforme (ex: 21/08/2026), le document est 100% saine et légitime.** L'alerte ne se déclenche qu'en cas d'hétérogénéité anormale.

#### D. Modèle Distant (attachedTemplate UNC / Web) :

- **Risque** : Attaque par *Template Injection*. Le document charge un modèle .dotm hébergé sur un serveur distant (ex: \\serveur\_pirate\malware.dotm ou https://...).
- ■ **Source de la preuve** : word/\_rels/settings.xml.rels -> Target='...'

#### E. Faux Caviardage & Texte Camouflé :

- **Faux Caviardage** : Une forme géométrique noire (<v:rect fillcolor='black'>) a été dessinée au-dessus du texte pour le masquer visuellement, mais le texte original reste présent en clair dans le code XML.
- **Texte Camouflé** : Texte configuré en couleur blanche (<w:color w:val='FFFFFF'>) ou en micro-police (< 2pt).
- ■ **Source de la preuve** : word/document.xml

#### F. Détection de la Langue & Transitions Suspectes :

- Analyse run par run de la langue déclarée (w:lang) pour identifier les transitions de langue suspectes dans le document (pouvant trahir une modification localisée ou une falsification de paragraphe).

#### G. Protection du Document & Verrouillages :

- Recherche de restrictions actives (w:documentProtection), des modes de verrouillage (lecture seule, formulaires) et des algorithmes de hachage de mot de passe utilisés pour protéger le document.

#### H. Texte Caché & Contrôles SDT :

- Repérage des balises de masquage de texte w:vanish (texte invisible à l'écran mais présent en binaire) et des contrôles de contenu structuré w:sdt susceptibles de contenir des métadonnées orphelines.

#### I. Historique des Commentaires Internes :

- Extraction intégrale des commentaires du fichier word/comments.xml (nom de l'auteur, date de rédaction et contenu brut du commentaire), souvent oubliés lors du nettoyage.

## 2.2. Documents PDF (.pdf)

#### A. Structure & Mots-Clés Suspects (PDFiD) :

- Recherche d'objets actifs exécutables : /JavaScript, /JS, /AA (Auto-Action), /OpenAction, /Launch, /EmbeddedFiles.
- ■ **Source de la preuve** : PDFiD Moteur Python -> Analyse des objets PDF

#### B. Marqueurs de Révisions Incrémentales (%%EOF) :

- **Interprétation** : Un fichier PDF standard se termine par un seul marqueur %%EOF. S'il contient plusieurs marqueurs %%EOF, le document a subi des révisions incrémentales. L'outil extrait chaque version

précédente pour vérifier si des pages ou des signatures ont été masquées ou altérées postérieurement.

#### C. Outil de Collusion PDF (Comparaison Binaire 2 Fichiers) :

- Permet de comparer un PDF suspect par rapport à son original supposé pour extraire la matrice de différences exactes (textes modifiés, objets supprimés ou ajoutés).

#### D. Vérification Cryptographique des Signatures (PyHanko) :

- Inspecte la validité de la chaîne de confiance X.509 des certificats numériques et valide le tampon horodaté RFC 3161.

## 2.3. Documents Microsoft Excel (.xlsx, .xlsm, .xls)

### A. Séquence chronologique des Textes (sharedStrings.xml) :

- Dans le format XLSX, toutes les chaînes de texte saisies par l'utilisateur sont enregistrées dans un dictionnaire centralisé (xl/sharedStrings.xml) dans l'ordre chronologique de leur création.
- **Détection des textes orphelins (supprimés)** : Même si une valeur textuelle est supprimée ou modifiée dans une feuille de calcul, Excel ne la purge pas de sharedStrings.xml. Le logiciel croise les chaînes de sharedStrings.xml avec les cellules réellement actives de toutes les feuilles et isole les 'chaînes orphelines'.
- **Interprétation forensique** : Permet de reconstituer des pans entiers de données sensibles effacées, modifiées ou masquées à posteriori (historique de saisie).
- ■ **Source de la preuve** : xl/sharedStrings.xml vs xl/worksheets/sheet\*.xml (recherche d'index orphelins)

### B. Analyse des Formules et Cache de Calcul :

- Analyse et extraction des formules actives (balises <f>) et confrontation avec les résultats précalculés mis en cache (balises <v>). Cela permet de détecter des manipulations manuelles directes du cache (ex: forcer un résultat de cellule sans modifier la formule correspondante).

### C. Validation de la Chaîne de Calcul (calcChain.xml) :

- Validation croisée entre les entrées de la chaîne de calcul (xl/calcChain.xml) et les formules actives. Une incohérence peut révéler la présence de formules orphelines ou cachées dans le document.

### D. Feuilles Cachées (veryHidden) & Chemins Absolus :

- Détection des feuilles de calcul masquées sous l'état veryHidden (impossibles à réafficher via l'interface standard d'Excel). Extraction du chemin absolu local d'origine du classeur (x15ac:absPath) révélant l'environnement de stockage de l'auteur.

## 2.4. Analyse de Retouche d'Images (Error Level Analysis - ELA)

- **Principe de l'ELA** : L'Error Level Analysis ré-enregistre l'image à un niveau de compression JPEG de 95% et calcule la différence d'erreur pixel par pixel.

#### • Interprétation des résultats :

- *Zones uniformes / sombres* : L'image entière a le même taux de compression (Image d'origine non retouchée).
- *Zones très brillantes / très contrastées localement* : Indique une insertion, un montage ou un collage récent provenant d'une autre image avec un taux de compression différent.

- **Conversion automatique RGB JPEG** : Prise en charge transparente des images non-JPEG (PNG, BMP, TIFF, WebP).

## 2.5. Courriels & Messages Outlook (.eml, .msg)

### A. Structure OLE Compound File des Fichiers MSG :

- Les fichiers Outlook .msg sont des conteneurs binaires OLE. L'outil extrait nativement les flux de métadonnées (*Sender, To, Subject, Date, Message-ID, Message Class*).

### B. Authentification des En-têtes (SPF, DKIM, DMARC) :

- Analyse de la ligne Authentication-Results et des en-têtes réseau bruts (*Internet Headers*) pour valider l'authenticité des serveurs de relais.

### C. Décodage FILETIME Outlook (Thread-Index) :

- Extrait le timestamp brut du premier message de la conversation dans l'en-tête Base64 Thread-Index pour valider l'horodatage réel du serveur d'envoi.

### D. Divergence Texte / HTML (Phishing) :

- Calcule l'écart de longueur entre la version Texte brut et la version HTML du message. Un écart > 150 caractères indique du texte masqué en HTML pour tromper les filtres anti-spam.

### E. Extraction & Quarantaine des Pièces Jointes MSG :

- Extraction sécurisée de toutes les pièces jointes embarquées dans le fichier MSG avec calcul d'empreinte SHA-256 et bouton de téléchargement en quarantaine.

## 2.6. Stylométrie & Stéganographie ZIP

- **Richesse lexicale (Type-Token Ratio - TTR)** : Mesure la variété du vocabulaire. Un TTR < 25% indique un texte automatisé ou très répétitif.
- **Longueur moyenne des phrases** : Calculée en séparant la ponctuation ET les sauts de ligne ( $\backslash n$  /  $\backslash r$ ).
- **Stéganographie ZIP** : Détecte les fichiers dissimulés dans le conteneur ZIP qui ne sont pas déclarés dans la table [Content\_Types].xml.

## 2.7. Crédits & Bibliothèques Forensiques (33 Dépendances Contrôlées)

- **Didier Stevens** : PDF Tools (pdfid, pdf-parser) — [blog.didierstevens.com](http://blog.didierstevens.com)
- **Philippe Lagadec (decalage2)** : oletools (olevba, oleid, oletimes, oleobj, msodde, rtfobj, oledir, olebrowse) — [decalage.info](http://decalage.info)
- **Phil Harvey** : ExifTool — [exiftool.org](http://exiftool.org)
- **Matthias Valcke** : PyHanko — [github.com/MatthiasValcke/pyHanko](https://github.com/MatthiasValcke/pyHanko)
- **Poppler & QPDF** : Extraction de flux, polices & contrôle structurel (14 exécutables binaires).
- **Dam-FOR3K (avec l'aide de l'IA Antigravity)** : Conception & Interface

## 3. Méthodes d'Entrée & Conservation des Dates Système (OS)

L'application propose deux méthodes pour analyser un document, chacune ayant un impact direct sur les métadonnées système du disque (*FileModifyDate, FileAccessDate, FileCreateDate*) extraites par ExifTool :

### A. Mode Téléversement Navigateur (Glisser-Déposer) :

- **Mécanisme** : Pour des raisons de sécurité, les navigateurs web suppriment les dates du disque local lors du transfert. L'application enregistre alors un fichier temporaire sur la machine de l'analyste.
- **Impact Forensique** : Les dates système (*FileModifyDate*) afficheront l'heure exacte de l'analyse (ex: aujourd'hui à 16h25). *Note* : Les vraies dates internes du document (*PDF CreateDate*, *docProps*) restent intactes.

#### B. Mode Chemin d'accès Local Direct (Recommandé) :

- **Mécanisme** : L'analyste saisit le chemin d'accès absolu du fichier (ex: C:\Dossiers\Contrat.pdf). L'application lit le fichier directement sur le disque dur SANS créer de fichier temporaire.
- **Impact Forensique** : ExifTool extrait les **vraies dates système d'origine du disque**. La Ligne du Temps Forensique inclut ainsi l'horodatage *FileModifyDate* du fichier local original, garantissant une intégrité parfaite de la chronologie OS.

## 4. Traçabilité des Preuves (Source Location) & Cartographie des Emplacements

Chaque indicateur relevé par l'outil inclut son champ ■ **Source Location**. En voici une synthèse de référence :

| Catégorie d'Anomalie            | Emplacement de la Preuve (Source Location)                     | Rôle dans le Rapport                                          |
|---------------------------------|----------------------------------------------------------------|---------------------------------------------------------------|
| Convertisseur Web / Apple Pages | docProps/app.xml -> <Application><br>PDF Metadata -> /Producer | Prouve le logiciel hôte d'origine.                            |
| RSID Orphelin                   | word/document.xml -> Attribut w:rsidR                          | Prouve un copier-coller depuis une source externe.            |
| Attachement Modèle Distant      | word/_rels/settings.xml.rels -> Target                         | Prouve une tentative de Template Injection UNC/Web.           |
| Timestomping Sous-Secondes      | docProps/core.xml -> <dcterms:modified>                        | Prouve une modification manuelle de la date (.000000).        |
| Faux Caviardage                 | word/document.xml -> <v:rect fillcolor='black'>                | Prouve que le texte masqué visuellement est présent en clair. |

#### ■■ Avertissement de Méthodologie Forensique :

**IMPORTANT** : Ce logiciel est un assistant expérimental d'exploration et de tri. Dans le domaine de la forensic numérique, aucun résultat automatisé ne doit être accepté comme preuve définitive sans une corroboration manuelle. L'analyste doit vérifier de manière indépendante tous les événements, horodatages et anomalies en inspectant directement les structures de fichiers primaires à l'aide d'outils de référence indépendants.